

**LAPORAN MACHINE LEARNING
ANALISIS & IMPLEMENTASI DECISION TREE DAN NAIVE BAYES**



DISUSUN OLEH :

Ariel Tiansyahrullah	G1A024011
Ivan Der Ghifra	G1A024087
Khairi Makruf Fathorikan	G1A024111

Dosen Pengampu :

Ir. Arie Vatesia, S.T., M.TI., Ph.D., IPP.

**PROGRAM STUDI INFORMATIKA
FAKULTAS TEKNIK
UNIVERSITAS BENGKULU**

2026

BAGIAN A. ANALISIS KONSEP

1. Jelaskan kapan Decision Tree lebih cocok digunakan dibanding Naive Bayes untuk kasus prediksi kelulusan ini. Beri 2 alasan.

Jawab :

Decision Tree lebih cocok digunakan ketika pihak pengambil keputusan membutuhkan model yang mudah diinterpretasikan (*white-box model*). Aturan keputusan dalam bentuk diagram percabangan (*if-then*) jauh lebih intuitif dan transparan untuk dipahami oleh pihak kampus dalam mengevaluasi batas-batas nilai kelulusan dibandingkan angka probabilitas abstrak pada Naive Bayes. Alasan kedua, Decision Tree mampu menangani interaksi atau dependensi antarfitur secara alami tanpa memaksakan asumsi independensi. Hal ini sangat krusial pada data akademik mahasiswa, di mana fitur-fitur yang ada umumnya saling berkorelasi satu sama lain.

2. Asumsi "independen" di Naive Bayes. Sebutkan 2 pasang fitur di dataset yang kemungkinan melanggar asumsi ini dan jelaskan kenapa.

Jawab :

Asumsi independensi pada Naive Bayes menyatakan bahwa setiap fitur berkontribusi secara mandiri terhadap kelas target tanpa ada keterkaitan antarsatu sama lain. Dalam data mahasiswa, dua pasangan fitur yang kemungkinan besar melanggar asumsi ini adalah :

- IPK dan Jam Belajar: Mahasiswa yang mengalokasikan jam belajar mandiri lebih tinggi cenderung meraih nilai ujian yang lebih baik sehingga menghasilkan IPK yang lebih tinggi. Keduanya saling berkorelasi dan tidak berdiri sendiri.
- Kehadiran dan Nilai Tugas/Ujian (atau IPK): Tingkat kehadiran perkuliahan berbanding lurus dengan penguasaan materi dan pemenuhan syarat minimal akademik kampus. Mahasiswa dengan tingkat kehadiran rendah biasanya melewatkan materi penting dan tugas wajib, yang secara langsung menjatuhkan nilai akhir mereka.

3. Apa risiko overfitting pada Decision Tree di dataset ini? Bagaimana cara mengatasinya?

Jawab :

Risiko *overfitting* pada Decision Tree terjadi ketika pohon keputusan dibiarkan tumbuh terlalu dalam (*deep tree*) hingga menghafal *noise* atau pola spesifik pada data latih (*training set*). Akibatnya, model memiliki akurasi sangat tinggi (bahkan mendekati 100%) pada data latih, tetapi performanya anjlok ketika menguji data mahasiswa baru (*generalization error* tinggi). Untuk mengatasi hal tersebut, dapat diterapkan teknik pemangkasan (*pruning*), baik *pre-pruning* dengan membatasi kedalaman pohon (*max_depth*), membatasi batas minimal sampel untuk percabangan (*min_samples_split*), maupun menetapkan batas minimal daun (*min_samples_leaf*). Selain itu, validasi model

menggunakan *k-fold cross validation* atau beralih ke metode *ensemble* seperti Random Forest juga sangat efektif untuk meredam varians dan mencegah *overfitting*.

BAGIAN B. IMPLEMENTASI KODE, EVALUASI, VISUALISASI, DAN ANALISIS ERROR

1. Preprocessing

Pada tahap pertama, yaitu preprocessing, kami menggunakan dataset yang terdiri dari 200 data mahasiswa. Data yang digunakan memiliki beberapa atribut, yaitu IPK, IPS Terakhir, SKS Lulus, persentase presensi, dan status kerja. Sedangkan target yang ingin diprediksi adalah status kelulusan mahasiswa, yaitu Tepat Waktu atau Terlambat. Sebelum digunakan untuk proses pemodelan, kami melakukan pengecekan dan penanganan terhadap missing value. Pada dataset terdapat nilai kosong pada kolom IPK dan Presensi. Untuk kolom IPK, nilai yang kosong kami isi menggunakan nilai median, sedangkan pada kolom Presensi kami menggunakan nilai mean atau rata-rata.

Selanjutnya, karena Status Kerja dan Status Lulus masih berupa data kategorikal, kami melakukan proses encoding menggunakan LabelEncoder agar data tersebut dapat diproses oleh algoritma machine learning. Setelah preprocessing selesai, dataset kami bagi menjadi data training dan data testing dengan perbandingan 80 banding 20. Jadi, sebanyak 160 data digunakan untuk proses training dan 40 data digunakan untuk pengujian. Dengan tahapan preprocessing ini, data sudah dalam kondisi yang dapat digunakan untuk membangun dan menguji model machine learning.

```
df['IPK'] = df['IPK'].fillna(df['IPK'].median())
df['Presensi_Pct'] = df['Presensi_Pct'].fillna(df['Presensi_Pct'].mean())

le_kerja = LabelEncoder()
df['Status_Kerja_Enc'] = le_kerja.fit_transform(df['Status_Kerja'])

le_target = LabelEncoder()
df['Target'] = le_target.fit_transform(df['Status_Lulus'])

feature_cols = ['IPK', 'IPS_Terakhir', 'SKS_Lulus', 'Presensi_Pct', 'Status_Kerja_Enc']
X = df[feature_cols]
y = df['Target']

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42, stratify=y
)
```

Gambar 1 Value pada atribut IPK dan Presensi

2. Modeling dan Bukti Overfitting

Pada tahap modeling, kami menggunakan tiga model machine learning untuk membandingkan performanya. Model pertama adalah Decision Tree dengan max_depth

sama dengan 3. Pembatasan kedalaman ini digunakan agar struktur pohon keputusan tidak terlalu kompleks.

Model kedua adalah Decision Tree dengan `max_depth` None, artinya tidak diberikan batas maksimal kedalaman pohon. Model ini dapat membentuk aturan yang lebih kompleks berdasarkan data training. Model ketiga adalah Gaussian Naive Bayes, yang menggunakan pendekatan probabilistik untuk melakukan klasifikasi. Ketiga model tersebut kemudian dilatih menggunakan data training dan digunakan untuk melakukan prediksi terhadap 40 data testing. Setelah mendapatkan hasil prediksi, kami melakukan evaluasi untuk mengetahui model mana yang memberikan performa terbaik.

```
dt_depth3 = DecisionTreeClassifier(max_depth=3, random_state=42)
dt_depth3.fit(X_train, y_train)

dt_none = DecisionTreeClassifier(max_depth=None, random_state=42)
dt_none.fit(X_train, y_train)

gnb = GaussianNB()
gnb.fit(X_train, y_train)

models = {
    'DT (max_depth=3)': dt_depth3,
    'DT (max_depth=None)': dt_none,
    'Gaussian Naive Bayes': gnb
}
```

Gambar 2 Kode Implementasi Tiga Model Klasifikasi

3. Evaluasi

Untuk mengevaluasi ketiga model, kami menggunakan empat metrik, yaitu Accuracy, Precision, Recall, dan F1-Score. Selain itu, kami juga membuat Confusion Matrix untuk melihat jumlah prediksi yang benar dan salah dari masing-masing model. Berdasarkan hasil pengujian, Decision Tree dengan `max_depth` sama dengan 3 memperoleh Accuracy sebesar 80%, Precision sebesar 83,20%, Recall sebesar 80%, dan F1-Score sekitar 80,80%.

Kemudian Decision Tree dengan `max_depth` None memperoleh hasil paling tinggi, yaitu Accuracy sebesar 85%, Precision sekitar 85,09%, Recall sebesar 85%, dan F1-Score sekitar 83,82%. Sedangkan Gaussian Naive Bayes memperoleh Accuracy sebesar 80%, Precision sebesar 80%, Recall sebesar 80%, dan F1-Score sebesar 80%. Dari hasil tersebut dapat disimpulkan bahwa Decision Tree dengan `max_depth` None menjadi model dengan performa terbaik pada dataset yang kami gunakan karena memiliki nilai Accuracy, Precision, Recall, dan F1-Score yang paling tinggi dibandingkan dua model lainnya.

```
eval_df = pd.DataFrame(metrics_list)
print(eval_df[['Model', 'Accuracy', 'Precision', 'Recall', 'F1-Score']])


for item in metrics_list:
    print(f"\n{item['Model']} Confusion Matrix:")
    print(item['CM'])
```

Gambar 3 Kode Implementasi Evaluasi Model dan Confusion Matrix

4. Visualisasi

Selanjutnya kami membuat Confusion Matrix untuk masing-masing model. Confusion Matrix digunakan untuk melihat bagaimana model melakukan klasifikasi terhadap dua kelas, yaitu Tepat Waktu dan Terlambat. Pada Decision Tree dengan max_depth 3, terdapat 23 data Tepat Waktu yang berhasil diprediksi dengan benar dan 9 data Terlambat yang berhasil diprediksi dengan benar. Sementara itu terdapat 6 data Tepat Waktu yang diprediksi sebagai Terlambat dan 2 data Terlambat yang diprediksi sebagai Tepat Waktu.


Pada Decision Tree dengan max_depth None, terdapat 28 data Tepat Waktu yang diprediksi dengan benar dan 6 data Terlambat yang diprediksi dengan benar. Kesalahannya adalah 1 data Tepat Waktu diprediksi sebagai Terlambat dan 5 data Terlambat diprediksi sebagai Tepat Waktu. Sedangkan pada Gaussian Naive Bayes, terdapat 25 data Tepat Waktu dan 7 data Terlambat yang berhasil diprediksi dengan benar. Kemudian masing-masing terdapat 4 data yang mengalami kesalahan prediksi. Dari Confusion Matrix ini juga terlihat bahwa Decision Tree dengan max_depth None menghasilkan jumlah prediksi benar paling banyak.



Gambar 4. Visualisasi Pohon Keputusan (Decision Tree)

Gambar tersebut menampilkan struktur pohon keputusan (Decision Tree) dengan kedalaman maksimal 3 (max_depth=3) yang digunakan untuk memprediksi kelulusan mahasiswa ke dalam dua kelas, yaitu Tepat Waktu dan Terlambat. Proses klasifikasi diawali

pada *root node* dengan membagi 160 sampel data berdasarkan atribut IPK (fitur penentu utama dengan ambang batas $\leq 2,618$). Jika kondisi IPK terpenuhi (True), evaluasi dilanjutkan ke cabang kiri dengan memeriksa jumlah SKS_Lulus ($\leq 103,5$) dan fitur pendukung seperti Presensi_Pct serta Status_Kerja_Enc. Sebaliknya, jika IPK lebih dari 2,618 (False), cabang kanan mengevaluasi variabel Status_Kerja_Enc ($\leq 0,5$) dan IPS_Terakhir ($\leq 3,439$). Setiap *leaf node* (simpul akhir) memberikan hasil keputusan beserta tingkat keberagaman data (*gini index*) dan distribusi sampelnya. Model ini memperlihatkan bagaimana kombinasi antara nilai akademis (IPK, SKS, IPS) dan faktor non-akademis (persentase presensi dan status kerja) membentuk aturan keputusan untuk memprediksi ketepatan waktu kelulusan.



Gambar 5. Grafik Perbandingan Kinerja Model Klasifikasi

Gambar di atas menampilkan grafik batang perbandingan kinerja tiga model klasifikasi—Decision Tree dengan $\text{max_depth}=3$, Decision Tree tanpa batasan kedalaman ($\text{max_depth}=\text{None}$), dan Gaussian Naive Bayes—berdasarkan empat metrik evaluasi, yaitu Accuracy, Precision, Recall, dan F1-Score. Secara umum, model Decision Tree ($\text{max_depth}=\text{None}$) mencatatkan performa terbaik secara konsisten di semua metrik dengan skor sekitar 0,85. Sementara itu, model Gaussian Naive Bayes menunjukkan hasil yang stabil dan identik di setiap metrik pada nilai 0,80. Untuk Decision Tree ($\text{max_depth}=3$), performanya berada di kisaran nilai 0,80 hingga 0,83, di mana nilai *precision* dan *F1-score*-nya sedikit lebih tinggi dibandingkan skor *accuracy* dan *recall*. Hasil ini menunjukkan bahwa model Decision Tree tanpa pembatasan kedalaman mampu menangkap pola data secara paling optimal dibandingkan kedua model lainnya pada eksperimen ini.

5. Analisis Error

Analisis kesalahan (*misclassification*) pada model Decision Tree ($\text{max_depth}=3$) menunjukkan bahwa kesalahan prediksi didominasi oleh kasus *False Positive* dan *False Negative* pada sampel data uji yang berada di sekitar batas keputusan (*decision boundary*). Kasus *False Positive* terjadi ketika mahasiswa yang sebenarnya terlambat diprediksi tepat waktu, umumnya disebabkan oleh nilai IPK mahasiswa yang berada di atas ambang batas ($> 2,62$), namun skor keseluruhannya tergerus oleh persentase presensi yang rendah atau statusnya yang sedang bekerja. Sebaliknya, kasus *False Negative* dialami oleh mahasiswa dengan IPK relatif rendah ($\leq 2,62$) tetapi berhasil lulus tepat waktu karena terkompensasi oleh tingginya akumulasi SKS lulus (≥ 104) dan presensi yang maksimal.

Penyebab utama dari kesalahan ini adalah pembatasan kedalaman pohon ($\text{max_depth}=3$) yang memaksa model melakukan *pruning* awal, sehingga aturan keputusan yang terbentuk terlalu sederhana dan gagal menangkap kombinasi linear kompleks dari variabel pembuat data. Selain itu, penggunaan metode *imputation* (median pada IPK dan *mean* pada Presensi) secara tidak langsung menggeser nilai asli sampel data *missing* mendekati rata-rata populasi, yang berakibat pada ketidakakuratan klasifikasi sampel marginal. Untuk mengatasi keterbatasan ini, perbaikan dapat dilakukan dengan mengoptimalkan kedalaman pohon melalui *Grid Search*, menerapkan algoritma *ensemble* seperti Random Forest atau XGBoost, serta melakukan *feature engineering* dengan membuat indikator gabungan sebelum proses pemodelan.

BAGIAN C. REKOMENDASI DAN ETIKA

1. Rekomendasi Model

Berdasarkan hasil evaluasi metrik kinerja, model Decision Tree ($\text{max_depth}=\text{None}$) menjadi pilihan paling direkomendasikan untuk diterapkan oleh pihak kampus. Model ini secara konsisten unggul dibandingkan dua model lainnya dengan mencatatkan skor tertinggi pada seluruh metrik evaluasi—yaitu *accuracy*, *precision*, *recall*, dan *F1-score*—di kisaran nilai 0,85. Sebagai perbandingan, model Decision Tree dengan batasan kedalaman ($\text{max_depth}=3$) hanya mencapai performa di kisaran nilai 0,80 hingga 0,83, sedangkan Gaussian Naive Bayes berada stabil di angka 0,80. Tingginya nilai *recall* dan *precision* pada Decision Tree tanpa batasan kedalaman menunjukkan bahwa model ini sangat andal dalam meminimalkan risiko salah prediksi, sehingga pihak kampus dapat mengidentifikasi mahasiswa yang berpotensi mengalami keterlambatan lulus secara lebih akurat untuk segera diberikan intervensi akademik.

2. Bias & Etika

Penggunaan fitur sensitif seperti Penghasilan_Ortu dan Jenis_Kelamin dalam model prediksi penetapan beasiswa berpotensi menimbulkan bias sistematis yang merugikan kelompok mahasiswa tertentu. Jika model dilatih menggunakan data historis yang sudah mengandung diskriminasi implisit, algoritma dapat mendeprioritaskan mahasiswa dari latar belakang ekonomi rendah atau gender tertentu secara tidak adil. Untuk memitigasi dampak etis ini, langkah utama yang harus dilakukan adalah menerapkan *algorithmic fairness* dengan mengeluarkannya (*feature removal*) dari himpunan data pelatihan jika tidak relevan secara akademik. Selain itu, kampus perlu menerapkan prinsip *human-in-the-loop*, di mana keputusan akhir penerimaan beasiswa tidak sepenuhnya diserahkan kepada otomatisasi AI, melainkan tetap diverifikasi secara manual oleh komite Beasiswa melalui proses tinjauan holistik dan audit berkala terhadap keadilan prediksi model.

3. Simulasi Kasus Mahasiswa

Untuk kasus mahasiswa yang memiliki IPK tinggi namun persentase kehadiran rendah, model Decision Tree dan Gaussian Naive Bayes berpotensi memberikan hasil prediksi yang berbeda akibat perbedaan mendasar pada mekanisme kerja keduanya. Model Decision Tree ($\text{max_depth}=3$) diprediksi akan mengklasifikasikan mahasiswa tersebut ke dalam kategori Tepat Waktu, karena aturan (*rule*) pertama pada *root node* langsung memisahkan data berdasarkan ambang batas IPK ($> 2,618$), sehingga cabang utama keputusan sudah mengarah pada kelulusan tanpa terlalu terpengaruh oleh variabel kehadiran di simpul bawah. Sebaliknya, model Gaussian Naive Bayes bekerja secara probabilistik dengan memperhitungkan kontribusi seluruh variabel independen secara simultan berdasarkan asumsi independensi; akibatnya, nilai persentase kehadiran yang sangat rendah dapat secara drastis menurunkan nilai probabilitas gabungan (*posterior probability*) dan berisiko mengubah prediksi akhir menjadi Terlambat.